LOCAL LLM · POLICY ANALYSIS

의정 이슈 레이더

광역 지방의회 회의록 기반
정책 이슈 트렌드 분석 및 흐름 예측



팀명 : 꺼드럭'S

최홍석, 전영주, 허민지, 임경빈, 권준, 김권우

02

왜 로컬 AI로 설계했는가

데이터 이용조건과 재현성 요구를 시스템 제약으로 반영

외부 상용 LLM API

회의록 원문 외부 전송
제3자 서버 처리
보존 정책 통제 어려움

사용 불가

로컬 오픈 모델

Arctic 임베딩
BGE 재순위
Ollama Qwen3:8b

원문 외부 전송 0

재현 가능한 제출

모델명·revision
라이브러리 버전
실행 스크립트
근거 회의록

외부 공공데이터는 별도 참고 계층이며, 공식 예측 학습 입력에는 포함하지 않습니다.

지방정책 이슈 트렌드 분석 및 흐름 예측

배경

선도 정책의
타 지자체 확산 사례 존재

방대한 회의록으로
정책 흐름 파악에 한계



목적



국회도서관 회의록 빅데이터를 AI로 분석
지역별 정책 태동 · 이슈 트렌드 및 향후 흐름 파악

- 국민 알 권리 보장
- 의정활동 지원

최종 목표

1. **주요 이슈 키워드 식별**
2. **데이터 내 최초 관측**
   제공 데이터 범위 내 최초 관측 시점
3. **타 지방의회 흐름**
4. **향후 확산 가능성**
5. **근거 회의록 제시**

향후 예측: 확산 가능성을 항목별 서술형으로 제시

근거 회의록: 회의록명 · 회의일자 · 원문 구간 함께 제시

정책 근거와 흐름을 연결하는 AI 분석 시스템

의정 이슈 레이더 전체 아키텍처

회의록 데이터에서 정책 전망과 시각화까지



회의록을 정리하고, 정책 흐름을 분석해 근거와 함께 보여줍니다

05

원문 정합화 Before / After

JSON 내부 HTML을 분석 가능한 canonical 발화 단위로 변환

BEFORE · 원본 JSON + HTML

MTG_DE : 20240216

RASMBLY_NM : 경기도의회

MTGNM : 본회의

MINTS_NM : 본회의 회의록 제373회

MINTS_HTML : HTML 태그가 포함된 원문

AFTER · canonical 발화

필드	정제 결과
chunk_id	고정 ID
council / date	경기도의회 / 2024-02-16
meeting_name	본회의 회의록 제373회
agenda / speaker	안건명 / 발화자·역할
text	HTML 제거·공백 정규화
source_line_no	원본 위치 추적

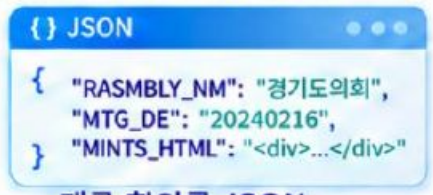
2,057,214행 · 34개 파일 · 빈 발언 0 · 깨진 문자 0

정제 텍스트와 원문 근거 위치를 같은 행에 보존

출처: 국회도서관 국가학술정보 클라우드
데이터셋 > 2026 DATA·AI 분석 경진대회 > 광역 지방의회 회의록 데이터셋

데이터 확보·구조 분석

1 회의록 데이터 확보



제공 회의록 JSON

2 HTML 구조 분석



추출 규칙 생성

발언 정리·표준화

3 발언 추출·정제



안건 · 발언자 · 본문

4 메타데이터 연결



날짜 · 의회 · 출처 표준화

검색 데이터 준비

5 청킹



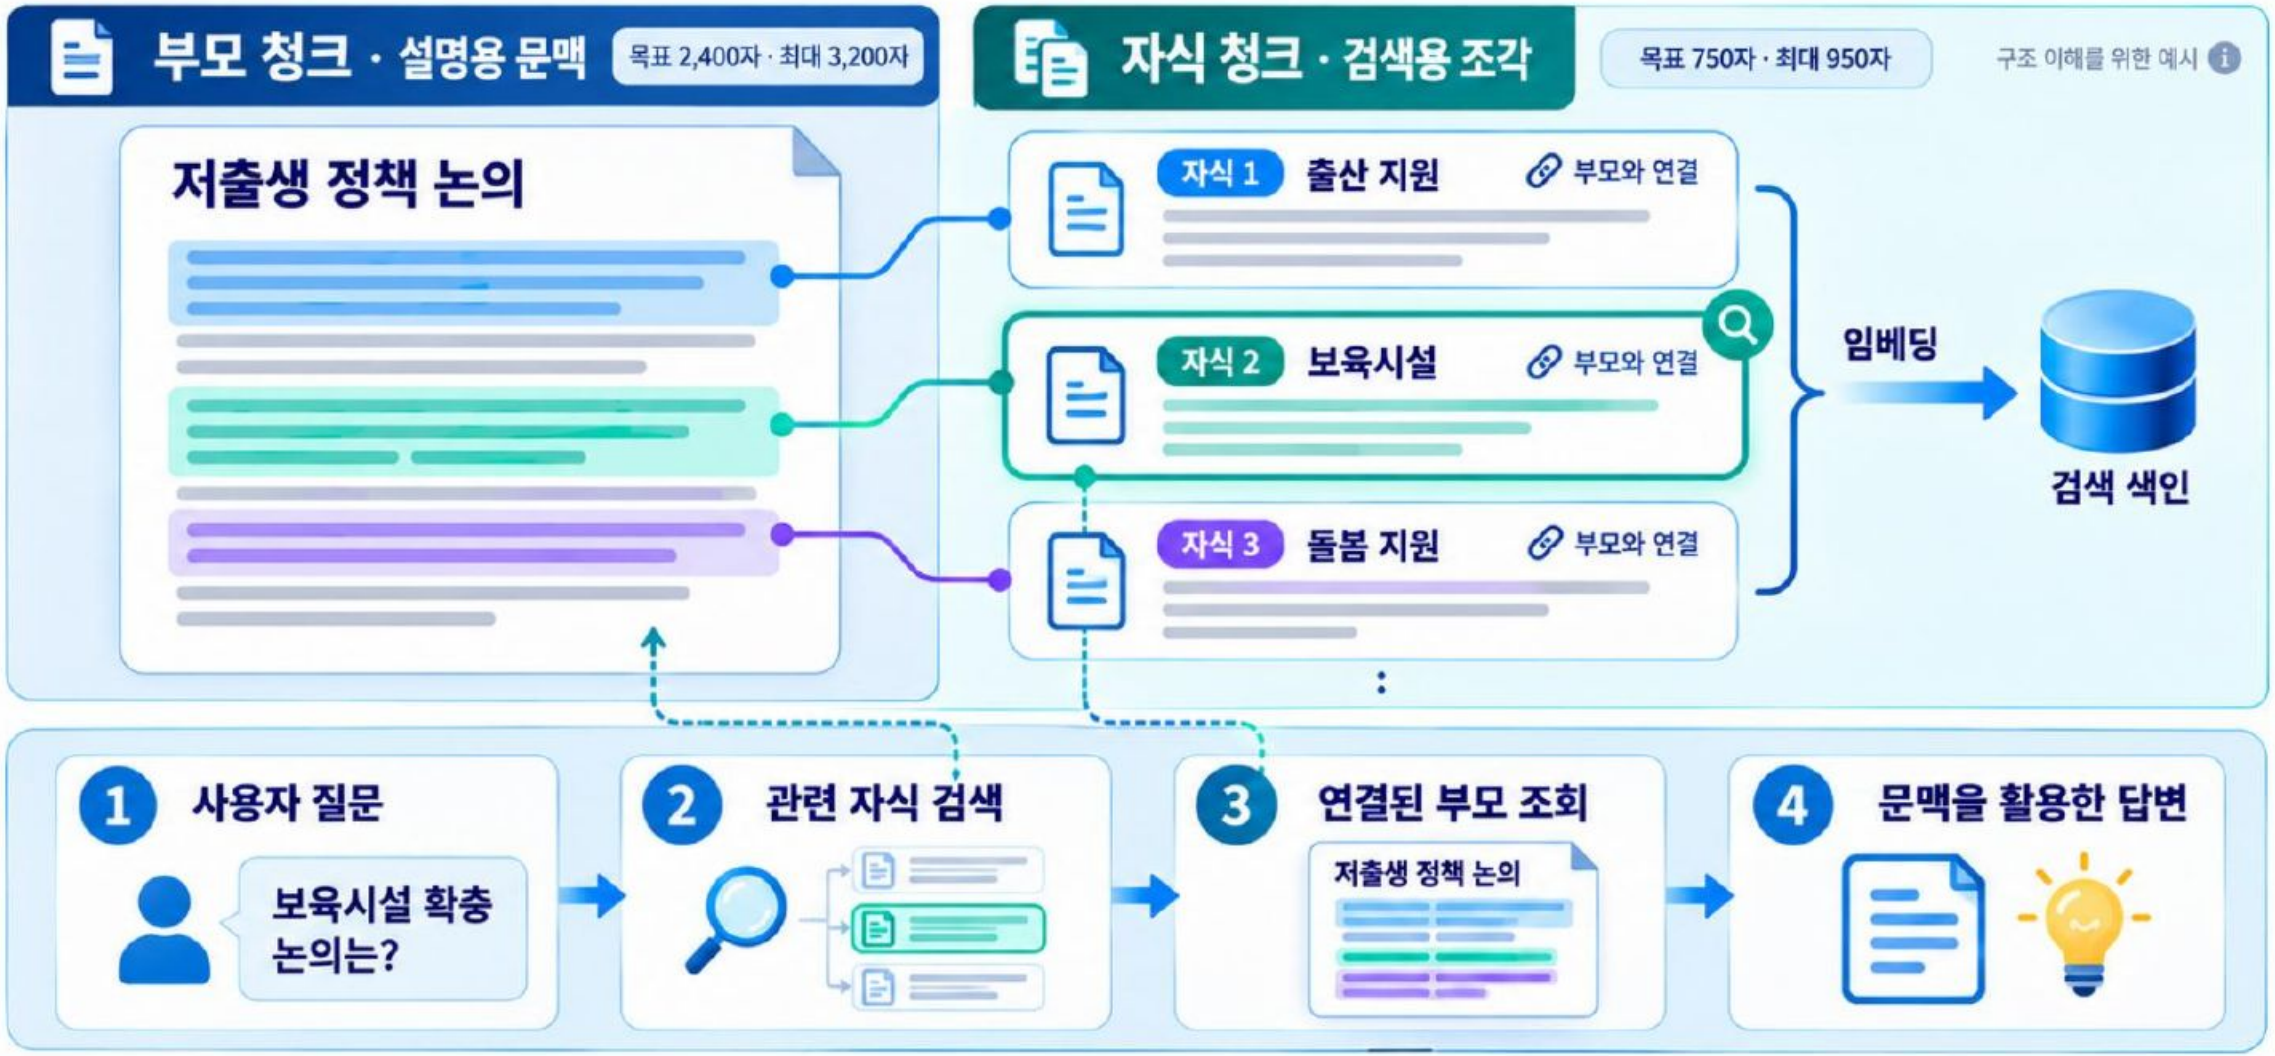
검색·문맥 단위 구성

6 임베딩·색인 구축



의미 검색 · 키워드 검색

부모·자식 청킹의 구조와 검색 흐름



08

임베딩 입력·모델 성능 비교

동일 질의와 동일 검수 라벨로 입력 구성과 모델을 각각 평가

① Raw 본문 vs Enriched 본문

입력	nDCG@10	P@10	Recall@20	MRR
Raw	0.8928	0.9750	0.5826	1.0000
Enriched	0.8871	0.9667	0.5744	0.9896

Raw가 근소 우세, 95% 신뢰구간은 0 포함 → 실질 동률

② Arctic-ko vs KURE

모델	nDCG@10	P@10	Direct P	행/초
Arctic-ko	0.8969	0.9833	0.8083	58.95
KURE	0.8657	0.9750	0.7833	56.25

Arctic가 검색 순위 품질과 처리율에서 우세

최종 선택

dragonkue/snowflake-arctic-embed-l-v2.0-ko

Raw 본문 · 1024차원 · L2 정규화 · float16

메타데이터는 벡터에 섞지 않고
지역·연도 필터와 근거 표시에 사용

임베딩 및 벡터 DB 선정

모델 비교부터 저장소 선정까지, 회의록 근거 검색 기반 구축

1 임베딩 모델 선정

자체 평가: 동일 Raw · 60,000청크 · 대표 질의 12개

비교 항목	Snowflake Arctic 한국어 ✓	KURE-v1
외부 검색 벤치마크 평균 점수	**0.740433**	0.727739
자체 평가 NDCG@10 ↑	**0.8969**	0.8657
임베딩 처리율 ↑	**58.95행/초**	56.25행/초

- **NDCG@10**: 상위 10개 검색 결과의 순위·관련도 평가
- Retrieval benchmark 데이터셋 7종 평균

선정 근거

- 평균 검색 품질
- 임베딩 처리율을 고려해 Snowflake Arctic 한국어 선정

2 벡터 DB 선정

동일 Snowflake Arctic 한국어 벡터 901,358개 · HNSW 비교

조건 / DB	p50(ms) ↓	p95(ms) ↓	Recall@10 ↑
일반 / ChromaDB	1.42	2.14	0.87
일반 / pgvector	2.75	4.31	0.95
지역+연도 / ChromaDB	586.29	861.08	1.00
지역+연도 / pgvector	**3.97**	**8.18**	**1.00**

p50: 중앙 지연시간 · **p95:** 95백분위 지연시간

지역·연도 필터 검색 p50 약 148배 빠름

메타데이터 조건 검색 · SQL 집계 · 원문 연결

최종 저장소: PostgreSQL + pgvector

정책 이슈 검색 및 흐름 분석

관련 발언 검색부터 정책 이슈 구성·관측 흐름 분석까지

1 정책어·질문 입력



분석할 정책 주제 입력

2 검색·재정렬



의미·키워드 검색 결합

Dense + BM25 → RRF
Cross-Encoder 재정렬

3 정책 이슈 구성



관련 발언 확장·군집화

유사도 그래프 기반

4 관측 흐름 분석



최초 관측·의회별 논의 순서

월별 언급량 집계



공공데이터 참고 보강 | 법제처 · 열린국회정보 · KOSIS 국가통계포털

검색 → 재정렬 → 군집화에서 데이터가 줄어드는 과정

전체 90만 청크를 모두 LLM에 넣지 않고 단계별 후보 축소

전체 검색 인덱스

901,358개

Arctic 임베딩 + BM25

1차 후보 검색

50개

Dense·BM25 결과를 RRF 결합

BGE 재정렬

Top 10

질의-문서 쌍을 다시 평가

이슈 확장

500개

상위 seed 주변 유사 발언 확장

기준 통과

358개

유사도·중복·문맥 필터

최종 선택 군집

158개

94개 군집 중 seed 포함 군집

숫자는 출산율 저하 대응 정책 프로토타입 실행 사례이며, 질의와 문턱값에 따라 달라집니다.

② 코사인 유사도 기반 이슈 군집

유사한 발언을 연결하고 같은 정책 이슈로 묶기

Python · 핵심 코드

```python
union_find = UnionFind(count)

for start in range(0, count, block_size):
    end = min(start + block_size, count)
  # 정규화 벡터의 코사인 유사도 계산
    similarities = vectors[start:end] @ vectors.T

    for local_index in range(end - start):
        global_index = start + local_index
    # 임계값 이상인 발언 번호 추출
        linked = np.flatnonzero(
            similarities[local_index] >= threshold
        )
    # 자기 자신과 중복 비교 제외
        linked = linked[linked > global_index]
    # 연결된 발언 그룹 병합
        for other in linked.tolist():
            union_find.union(global_index, int(other))
```

1 유사도 계산

정규화된 발언 벡터의 내적



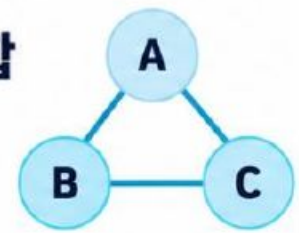
2 임계값으로 연결

기준 이상인 발언 쌍에 연결 생성



3 Union-Find로 병합

직접·간접 연결된 발언을
한 군집으로



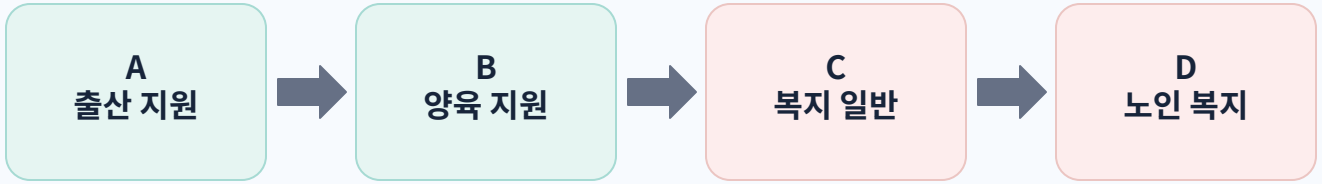
발언 간 의미 유사성을 정책 이슈 묶음으로 전환

출처: src/20_expand_cluster_issue.py / graph_clusters() · 핵심 부분 발췌

Union-Find 과병합을 어떻게 막았는가

연결 사슬로 다른 주제가 합쳐지는 문제를 다중 안전장치로 제어

과병합 위험



A-B, B-C, C-D가 각각 연결되면 A와 D도 같은 군집이 되는 chain effect

적용한 안전장치

① 중심 유사도 ≥ 0.45

② 청크 간 edge ≥ 0.72

③ 동일본문·부모 중복 제거

④ seed 포함 군집만 선택

⑤ 검수 후 issue_id 고정

유사도 문턱

낮으면 잡음·과병합

높으면 근거 누락

Seed 비율

질의 seed가 충분히

포함되는지 확인

지역·기간 분포

한 지역·회의 편중

가짜 확산 점검

사람 검수

대표 근거 확인

고정 ID로 전환

‘전파’는 인과관계가 아니라 제공 데이터에서 확인된 최초 관측 순서입니다.

정책 논의 정량 예측

과거 논의 기록으로 다음 달의 논의 여부와 언급량을 예측

월별 논의 데이터



월별 언급량
최근 논의 활동 기록

논의 지속 여부

다음 달에도 논의될까?

최근 활동률 기준선
active_ratio_baseline

논의 지속 예측값



언급량 예측

다음 달 몇 건 언급될까?

포아송 회귀
Poisson Regression

예상 언급량



첨부 평가 기록

시간순 검증: 이전 월로 학습하고 이후 월과 비교

논의 여부 · F1 0.8814

언급량 · MAE 7.12건

예측 모델과 평가 지표

다음 달 지속 여부는 분류, 언급량은 카운트 회귀로 분리

분류

다음 달에도 논의되는가

후보: Logistic Regression

활성비율 · 전월 상태 기준선

카운트 회귀

다음 달 몇 건 논의되는가

후보: Poisson Regression

3개월 평균 · 전월 건수 기준선

시간순 검증

과거 월 학습 → 다음 달 예측

10 Rolling folds · 미래 누출 방지

평가 항목	선택 결과	전월 유지 대비	해석
논의 지속 F1	0.8814	+0.0621	정밀도·재현율 조화
언급량 MAE	7.1224	29.83% 개선	평균 약 7.1건 오차
언급량 RMSE	10.0425	24.31% 개선	큰 오차에 더 큰 벌점
방향성 정확도	0.76	+0.74	증가·유지·감소

왜 Poisson인가

0 이상의 발생 건수

음수 예측 방지

작은 표본에 안정적

시간순 MAE가 최저

선택: active_ratio_baseline + poisson_regression

로컬 LLM 기반 전망 설명 및 AI 에이전트

예측 결과와 원문 근거를 종합해 정책 전망을 설명



로컬 LLM과 챗봇의 정확한 역할

검색·예측 모델을 대신하지 않고 근거를 구조화해 설명

왜 로컬 LLM을 사용했나

- 회의록 원문 외부 전송 금지
- 긴 근거를 읽기 쉬운 답변으로 변환
- 검색·타임라인·예측을 한 형식으로 설명

챗봇이 하는 일

질문 의도 분류 → 근거 검색 호출 → 출처가 있는 답변 생성
모르는 내용은 추측하지 않고 '근거 부족'으로 응답

하지 않는 일: 임베딩 생성 · 군집 ID 결정 · 예측 수치 임의 생성

프롬프트 핵심 구조

[역할] 지방의회 정책 분석 보조자

[입력] 질문 + 검색 근거 + 타임라인 + 예측값

[규칙] 근거만 사용 · 날짜 표시 · 추측 금지

[출력] 답변 → 근거 → 관측 흐름 → 전망 → 한계

핵심 코드 3개

18_pgvector_retrieval.py	관련 원문을 찾고 순위를 정함	찾기
20_expand_cluster_issue.py	유사 발언을 하나의 이슈로 묶음	묶기
32_train_multi_issue_forecast.py	다음 달 지속 여부·건수를 평가	예측

한 문장 요약: 검색이 근거를 찾고, 군집화가 이슈를 만들며, 예측이 다음 달을 계산하고, LLM은 이를 설명합니다.

③ 외부 공공데이터 API 호출

허용된 공공데이터 서버를 조회하고 접근 이력을 기록

Python · 핵심 코드

```python
def _get(url, source, keyword, timeout=20) -> bytes:
    host = urllib.parse.urlparse(url).hostname
    if host not in ALLOWED_HOSTS:
   # law.go.kr / open.assembly.go.kr / kosis.kr 만 허용
        raise PolicyError(...)
    req = urllib.request.Request(url, headers=UA)
    with urllib.request.urlopen(req, timeout=timeout) as r:
        body = r.read()

# access_log.jsonl 에 시각·출처·검색어·바이트 수 기록
# 인증값은 기록 안 함
```

법제처 · 열린국회정보 · KOSIS

허용 주소 확인

ALLOWED_HOSTS로 요청 대상 제한

공공데이터 수신

urlopen()으로 API 응답 읽기

조회 이력 기록

언제·어디서·무엇을 조회했는지 기록

공공데이터를 참고해 회의록 분석 설명을 보완합니다

출처: src/external_policy_sources.py / _get() · 설명용 축약 코드

외부 공공데이터 선택·검증 규칙

로컬 LLM이 의도를 해석하고 코드는 허용 주소·검색어·시점을 검증

질문 해석
Qwen3:8b

→

정책어 검증
일반어 제거

→

허용 API
법제처·국회·KOSIS

→

시점·지역 필터
기준일 준수

→

참고 근거
예측과 분리

검증 항목	허용 기준	차단 또는 처리
전송 내용	짧은 정책어·통계표 ID	회의록 원문 전송 금지
검색어	중복 제거·개수 제한	일반어·형식 오류 제외
주소	사전 허용 API	임의 URL 호출 차단
시점	분석 기준일 이전	기준일 이후 별도 표시
활용	reference_only	예측 학습 미사용

후속 후보 점수

회의록 논의 30%

최근성 15%

기초 조례 25%

지역 수요 15%

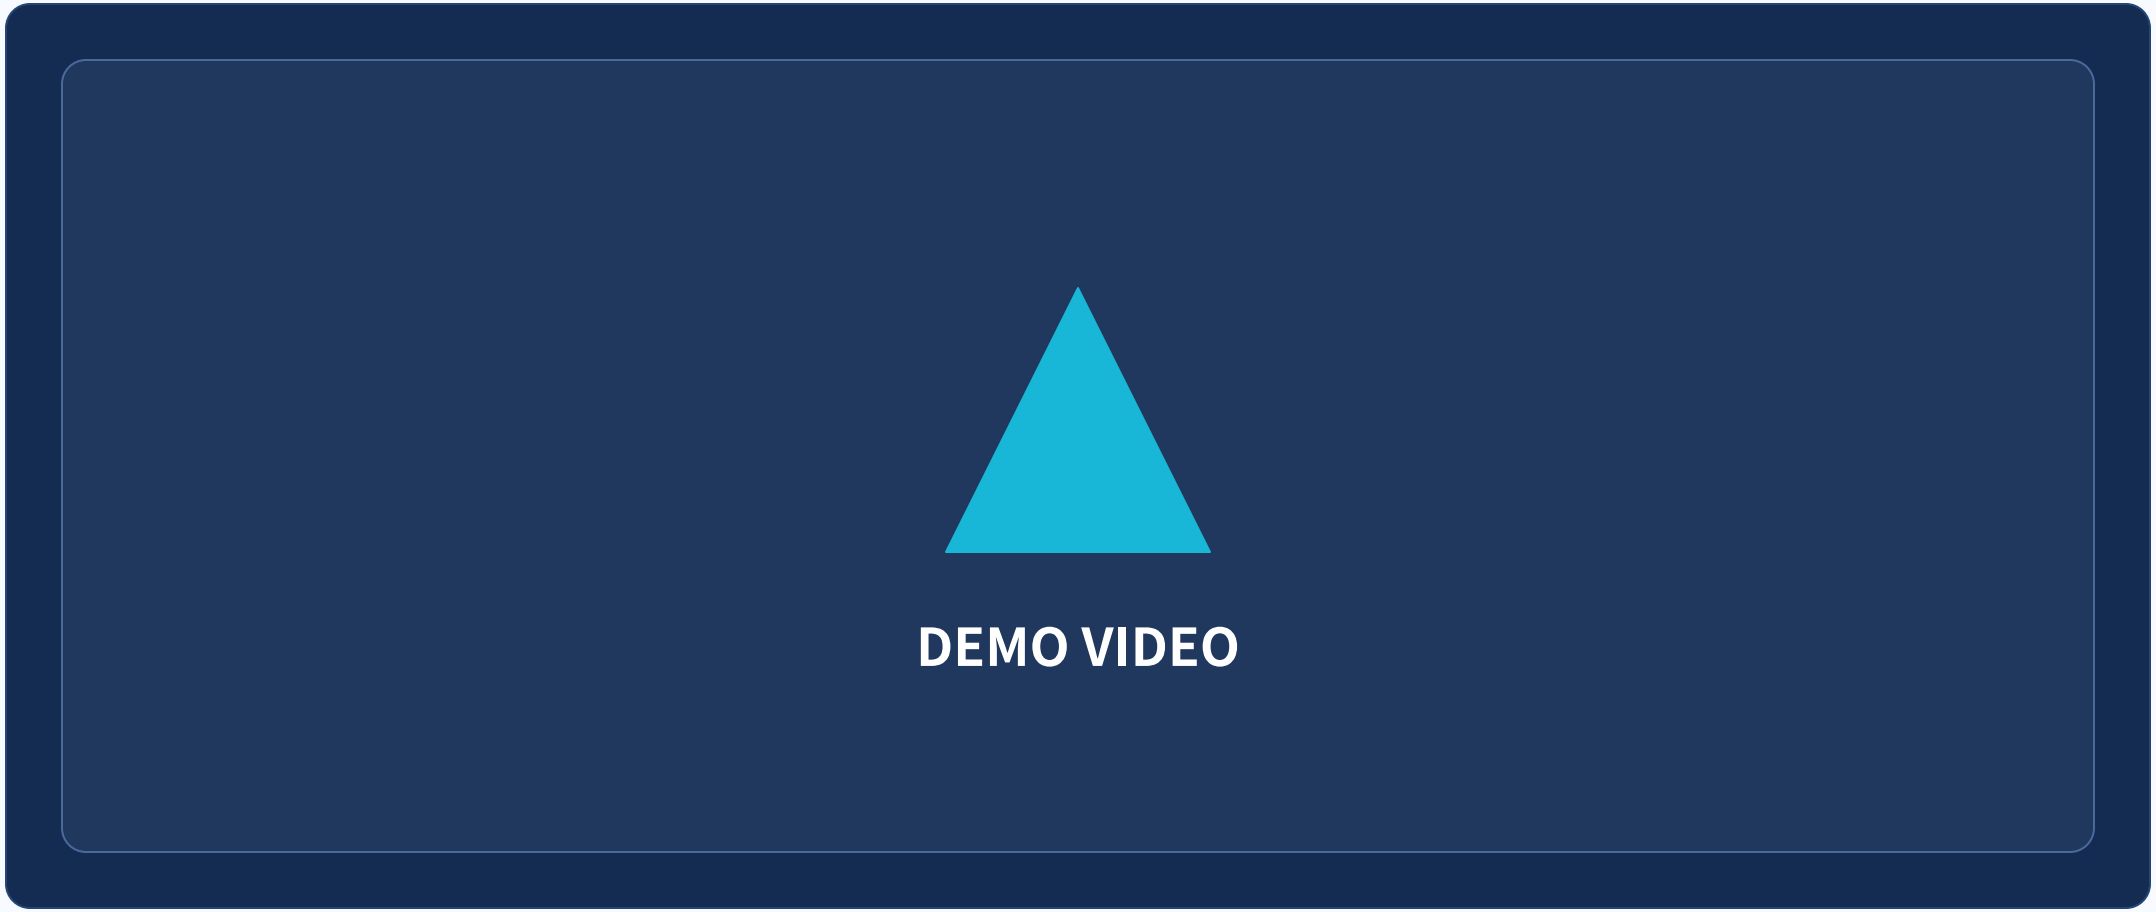
지속 가능성 15%

LLM은 숫자를 만들지 않고 설명만 수행

대회 공식 실행 기본값: 외부 참조 OFF

시연 영상

아래 영역에 발표용 데모 영상을 삽입하세요



PowerPoint → 삽입 → 비디오 → 이 장치 → 영상 선택

Q&A

궁금한 점을 말씀해 주세요

감사합니다

① 하이브리드 검색

Dense·BM25로 후보를 찾고 RRF로 검색 순위를 통합

Python · 핵심 코드

```python
# 질문을 벡터로 변환
query_vector = self.encoder.encode([query])[0]

# 의미가 가까운 발언 검색
dense_rows = self._search_pgvector(
    query_vector, dense_limit, filters
)

# 키워드 검색: 필터 인자 등은 생략
hits, bm25_tokens = self.bm25.search(
    query, candidate_k * 2, ...
)
# ... 검색 결과를 bm25_rows로 구성 ...

# 두 검색의 순위를 가중 결합
candidates = reciprocal_rank_fusion(
    dense_rows, bm25_rows, candidate_k,
    rrf_k=self.rrf_k,
    dense_weight=self.dense_weight,
    bm25_weight=self.bm25_weight,
)
```

Dense 의미 검색

단어가 달라도 비슷한 뜻 찾기

BM25 키워드 검색

정책명·검색 단어로 찾기

RRF 순위 통합

각 검색의 순위와 가중치 결합

의미와 키워드 검색의 장점을 결합해 관련 발언 후보를 확보

출처: src/council_vector_runtime.py / CouncilSearchService.search() · 설명용 발췌

질문 대비 용어 ① 검색·임베딩

평가위원 질문에 한 문장 정의와 프로젝트 적용을 함께 답하기

임베딩

문장을 의미를 보존한 숫자 벡터로 변환

Arctic-ko · 1024차원 · 정규화

RRF

서로 다른 검색 순위를 순위 기반으로 결합

Dense와 BM25의 점수 단위 차이를 피함

코사인 유사도

두 벡터 방향이 얼마나 비슷한지 측정

정규화 후 내적과 동일, 1에 가까울수록 유사

Reranker

상위 후보를 질의와 함께 다시 읽고 정렬

BGE로 최종 Top-K 정밀도 향상

BM25

질의 단어가 문서에서 얼마나 중요하게 등장하는지 계산

조례명·사업명·고유명사 검색 보강

nDCG@10

관련도가 높은 문서가 상위 10개에 잘 배치됐는지 평가

등급 라벨 0·1·2와 순서를 함께 반영

Dense 검색

표현이 달라도 의미가 비슷한 문서를 벡터로 검색

‘출산율 저하’와 ‘저출생 위기’ 연결

MRR

첫 관련 문서가 몇 번째에 나오는지 평가

검색 즉시 정답을 만나는 사용성 측정

답변 원칙: 정의 → 우리 코드에서의 역할 → 선택 근거 순서로 말합니다.

질문 대비 용어 ② 군집화·예측

과병합, F1, MAE, RMSE, Rolling Backtest 설명

Union-Find	**유사 연결을 같은 집합으로 빠르게 합치는 자료구조**	edge·centroid 문턱값과 seed 검수로 과병합 통제
Precision	**양성이라고 예측한 것 중 실제 양성 비율**	거짓 경보가 적은지 확인
Recall	**실제 양성 중 찾아낸 비율**	지속 이슈를 놓치지 않는지 확인
F1 score	**Precision과 Recall의 조화평균**	한쪽만 높은 모델을 피하고 지속 판단 균형 평가
Poisson 회귀	**0 이상 발생 건수의 평균을 설명하는 회귀 모델**	다음 달 회의록 언급 건수 예측
MAE	**예측 오차 절댓값의 평균**	평균적으로 몇 건 틀리는지 직접 해석
RMSE	**오차 제곱 평균의 제곱근**	큰 오차에 더 큰 벌점을 주는 안전 지표
Rolling Backtest	**과거로 학습해 바로 다음 시점을 반복 예측**	미래 정보 누출 없이 실제 운영 상황 재현

$$F1 = 2 \times Precision \times Recall \div (Precision + Recall)$$